Diseño e Implementación de un Framework de Big Data Analytics sobre Reseñas de Restaurantes en el Perú basado en Datos de Google Maps

Fabrizzio Marin, Bruno Herrera, Marx Rojas, Tadashi Vigo, Mario Auqui
Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
{sf.marinc, ba.herrerac, lm.rojasro, dt.vigop, mm.auquic}@alum.up.edu.pe

***Resumen*—Este artículo propone e implementa un framework de analítica de macrodatos para estudiar reseñas de restaurantes en el Perú a partir de datos públicos de Google Maps. El problema radica en la limitada capacidad de los actores gastronómicos para aprovechar el contenido generado por usuarios como evidencia sobre reputación y calidad del servicio. Se desarrolló un pipeline escalable de recolección, integración y análisis sobre una arquitectura medallón en Databricks, basado en web scraping y procesamiento distribuido. El corpus final reúne 39,947 restaurantes y aproximadamente 1.8 millones de reseñas, con predominio de calificaciones altas (78.13 %). Mediante K-Means se identificaron perfiles diferenciados de usuarios, incluyendo segmentos de baja participación con valoraciones altas y un grupo intensivo más heterogéneo (5.97 reseñas promedio, media 3.81). Por su parte, LDA detectó cinco tópicos dominantes asociados a comida, atención, ambiente y precio. Asimismo, las reseñas negativas resultaron significativamente más extensas que las positivas, evidenciando mayor carga informativa. En conjunto, los resultados confirman la utilidad de las reseñas como fuente masiva y replicable para caracterizar el mercado gastronómico peruano y apoyar la toma de decisiones.**

***Index Terms*—Big Data Analytics; Google Maps; reseñas en línea; minería de texto; K-Means; LDA; arquitectura medallón; restaurantes peruanos**

I. Introducción

En el Perú la gastronomía es, al mismo tiempo, industria e identidad nacional. Tras el boom gastronómico de la primera década del presente siglo, el país se posicionó entre los destinos culinarios más reconocidos del mundo y el sector creció hasta contar más de 220,000 establecimientos gastronómicos a nivel nacional. Todos ellos contribuyen cerca del 11.2 % del PBI, según cifras del MINCETUR [1]. No obstante, este crecimiento sin parangón trajo consigo el desarrollo de un mercado altamente informal, fragmentado y competitivo donde la diferenciación ya no se sostiene únicamente en la propuesta culinaria sino, de manera creciente en la calidad de la experiencia del cliente.

Medir dicha experiencia de manera sistemática es costoso. Las herramientas convencionales como las encuestas de NPS transaccional, el mystery shopping y las auditorías de servicio quedan solo al alcance de cadenas respaldadas por importantes líneas presupuestales de las que la microempresa gastronómica carece. Esta última, sin embargo, representa a la mayoría del tejido empresarial del sector.

Este vacío metodológico coexiste, paradójicamente, con una fuente de retroalimentación pública y muy económica: las reseñas en Google Maps. Allí, cualquier comensal puede dejar una valoración en formato de puntaje o texto, visibles para millones de usuarios, conviertiendo a esta plataforma en uno de los repositorios gastronómicos de Contenido Generado por Usuario (UGC, por sus siglas en inglés) más grandes del país. Con todo, esta fuente permanece sistemáticamente desaprovechada, pues la mayoría de los establecimientos no cuenta con procesos para monitorear ni interpretar este flujo continuo de retroalimentación. Los organismos rectores del sector como el Mincetur tampoco explotan su dimensión agregada para orientar política pública hacia la calidad del servicio.

En ese sentido, si bien a nivel individual, gestionar decenas de reseñas puede resultar viable manualmente, una analítica integral de la industria a nivel nacional rebasa con creces cualquier capacidad convencional. La literatura sobre opinion mining ha demostrado que el texto corto no estructurado de las de las reseñas en línea contiene señales consistentes sobre atributos de servicio como atención al cliente, tiempo de espera, reelación calidad-precio y condiciones del ambiente [2]. Extraer esas señales a escala requiere solvencia para combinar Procesamiento de Lenguaje Natural (NLP) y arquitecturas de cómputo distribuido que permitan operar sobre millones de documentos de manera eficiente y reproducible.

Más allá del problema de escala, existe una brecha concreta en la literatura sobre minería de opiniones en plataformas de reseñas por la que se concentra predominantemente en contextos anglosajones con agregadores como Yelp y TripAdvisor, y en corpus en inglés [2]. Por el contrario, estudios integrados,escalables y contextualizados para el sector gastronómico peruano son prácticamente inexistentes. El presente estudio pretende cubrir esa brecha y sus resultados preliminares confirman que el corpus construido contiene patrones territoriales, temporales y temáticos lo suficientemente estables como para producir insights accionables. Por lo tanto, el framework propuesto constituye una herramienta metodológica replicable con

aplicaciones directas en la gestión empresarial, la vigilancia competitiva y el diseño de intervenciones públicas orientadas a la excelencia del servicio en el rubro gastronómico peruano.

El presente trabajo se traza el objetivo general es diseñar e implementar un framework de Big Data basado en reseñas de Google Maps para caracterizar la estructura territorial, reputacional y temática del sector gastronómico peruano y evaluar su utilidad como insumo para la toma de decisiones. Para ello, se articulan los siguientes objetivos específicos, que en conjunto conforman un pipeline que integra web scraping, ingeniería de datos y analítica sobre arquitecturas de procesamiento distribuido:

- Construir un pipeline robusto de recolección, depuración e integración de datos a escala nacional sobre una arquitectura medallion en Databricks, garantizando trazabilidad y reproducibilidad en cada etapa del proceso.
- Describir la distribución geográfica y temporal de los establecimientos y de la actividad de reseñas, identificando patrones de concentración, visibilidad digital y evolución del comportamiento del consumidor a nivel nacional.
- Segmentar los establecimientos según sus perfiles de valoración mediante clustering K-Means, con el fin de identificar agrupaciones diferenciadas por categoría de establecimiento y percepción de servicio.
- Extraer los principales tópicos del corpus textual mediante LDA [3], [4], midiendo el enfoque en términos de coherencia semántica e identificando los atributos recurrentes de la experiencia gastronómica.
- Sentar una base analítica reutilizable para aplicaciones posteriores, incluyendo sistemas de recomendación, monitoreo continuo del mercado y generación de evidencia para la gestión empresarial y el diseño de políticas públicas sectoriales.

II. Revisión de literatura

La analítica de macrodatos aplicada a la industria gastronómica ha evolucionado desde enfoques descriptivos basados en reseñas y calificaciones hacia arquitecturas más integradas capaces de transformar el contenido generado por el usuario (UGC, por sus siglas en inglés) en inteligencia de negocio. En el contexto de los restaurantes, el UGC constituye una fuente clave de evidencia sobre la percepción del cliente, la calidad del servicio y el desempeño operativo del establecimiento. En particular, las calificaciones numéricas y las reseñas textuales funcionan como variables proxy de satisfacción, reputación e incluso de desempeño comercial, lo que ha motivado el uso de técnicas de aprendizaje automático, minería de texto y arquitectura de datos para capturar su valor analítico.

En este marco, diversos estudios han abordado la analítica de restaurantes desde perspectivas complementarias. En el ámbito de la adopción digital y la toma de decisiones, se ha evidenciado que la madurez digital de las empresas gastronómicas y de hospitalidad se relaciona con mejores capacidades de respuesta organizacional y mayor resiliencia operativa [5], [6]. De forma paralela, se han propuesto arquitecturas orientadas al monitoreo continuo del mercado, capaces de integrar múltiples fuentes de información y proporcionar una visión más amplia del entorno competitivo [7]. Estos trabajos son relevantes porque muestran que el valor del dato no se limita al análisis retrospectivo, sino que puede convertirse en soporte para decisiones estratégicas en tiempo casi real.

Otra línea de investigación se ha concentrado en la dimensión espacial y temporal del desempeño restaurantero. Los modelos espaciales han permitido estudiar cómo la aglomeración geográfica, la densidad de competencia y la localización influyen en la rentabilidad y sostenibilidad de los restaurantes [8]. De manera complementaria, los análisis de series temporales han mostrado que las variaciones en la reputación digital, particularmente en plataformas como Google Maps, pueden asociarse con cambios en el flujo de clientes y en los ingresos del negocio [9]. En conjunto, estos estudios confirman que la ubicación y la evolución temporal de la reputación digital son variables esenciales para comprender el comportamiento competitivo del sector.

Asimismo, el análisis del comportamiento del consumidor ha incorporado con mayor fuerza técnicas de procesamiento de lenguaje natural y agrupamiento no supervisado. Algunas investigaciones han utilizado clustering para segmentar clientes a partir de sus patrones de interacción y preferencia, con el fin de apoyar estrategias de marketing más precisas [10]. Otras han aplicado minería de texto sobre reseñas para identificar atributos operativos críticos, como calidad de la comida, rapidez del servicio, limpieza y atención al cliente, transformando comentarios cualitativos en indicadores útiles para la gestión [11], [12]. En la misma línea, el modelado de tópicos ha permitido detectar tendencias emergentes en preferencias gastronómicas y orientar procesos de innovación en menús y propuestas de valor [13]. Finalmente, los sistemas de recomendación híbridos han sido propuestos como mecanismos para personalizar sugerencias de restaurantes y mejorar la retención de usuarios en plataformas digitales [14].

A pesar de estos avances, la literatura presenta limitaciones importantes que justifican la presente investigación. En primer lugar, muchos estudios dependen de conjuntos de datos estáticos, reducidos o restringidos a una sola plataforma, lo que limita su escalabilidad y su capacidad para capturar dinámicas de cambio en el comportamiento del consumidor [5], [10]. En segundo lugar, varias propuestas se concentran en una sola dimensión analítica —por ejemplo, clasificación, segmentación o minería de texto— sin integrar en un mismo flujo las variables espaciales, textuales y reputacionales que caracterizan a los restaurantes en entornos digitales [8], [13]. En tercer lugar, persisten desafíos técnicos relacionados con la heterogeneidad de las fuentes, la calidad del dato, el sesgo geográfico y la limitada generalización de los modelos cuando se aplican a contextos distintos de aquellos para los que fueron entrenados.

Estas brechas muestran la necesidad de un enfoque más robusto, escalable e integrado que articule la ingesta masiva de UGC, el procesamiento estructurado de datos y la extracción de conocimiento útil para la toma de decisiones. En respuesta a ello, el presente estudio propone un marco de analítica de

macrodatos orientado a restaurantes en el contexto peruano, basado en una arquitectura Medallón que organiza el flujo de información en capas de Bronze, Silver y Gold. Sobre esta base, se integran mecanismos de recolección concurrente, normalización y enriquecimiento de datos provenientes de Google Maps, junto con técnicas de análisis espacial, procesamiento de lenguaje natural y modelado de interacciones usuario–restaurante. De este modo, la investigación busca superar las limitaciones de los enfoques fragmentados previos y construir una base metodológica sólida para el análisis, la segmentación y la recomendación en el sector gastronómico.

III. Materiales y métodos

La presente investigación adopta un diseño computacional y exploratorio fundamentado en analítica de macrodatos, desde la recolección, ingesta y almacenamiento de datos hasta la analítica avanzada y evaluación de resultados. Esta arquitectura modular, descrita a continuación, proporciona la robustez necesaria para procesar y analizar volúmenes masivos de información estratégica sobre el comportamiento del consumidor y la oferta gastronómica a través de reseñas en Google Maps.

III-A. Recolección de datos

La recolección se dividió en dos procesos secuenciales orientados a sortear las barreras de extracción de las aplicaciones web modernas, de tipo página única (SPA), tales como los sistemas de detección *anti-bot* y las limitaciones de memoria de la máquina ejecutora. Para ambas tareas, el entorno de programación base fue Python (≥ 3.11), complementado con librerías de alto rendimiento como `Playwright` para la ejecución asíncrona de raspado web y `Polars` para la rápida estructuración de datos.

III-A1. Extracción de restaurantes: El procedimiento inició con la creación de un censo digital exhaustivo de los locales de comida en el Perú utilizando los motores de búsqueda de Google Maps. Para mitigar las restricciones de paginación natural de la interfaz y evitar sesgos de cobertura espacial, se construyó un Orquestador Geográfico Masivo. Este componente iteró dinámicamente sobre un catálogo georreferenciado que contenía todos los 1873 distritos a nivel nacional, ordenados por provincia y región.

Se despacharon consultas jerárquicas automatizadas con el patrón `<tipo_restaurante> en el distrito de <distrito>, <provincia>, <región>, <país>` (por ejemplo, «pollería en el distrito de Miraflores, Lima, Lima, Perú») empleando un sistema de concurrencia controlada para no exceder los límites de limitación de tasa del servidor. Los registros obtenidos fueron estructurados y exportados directamente en una topología jerárquica de archivos CSV (carpetas por departamento y provincia, y archivos por distrito). Adicionalmente, se integró un mecanismo de reanudación algorítmica (reanudación automática) capaz de identificar directorios previamente completados, evitando la pérdida de información ante cortes de red y dotando al sistema de tolerancia a fallos.

Tabla I
Descripción de variables del dataset de Restaurantes

Variable	Descripción
id	Identificador único del local (*Place ID*)
url_place	Enlace canónico de Google Maps
title	Nombre comercial del restaurante
category	Clasificación del establecimiento
address	Dirección física completa
phoneNumber	Número de contacto local
completePhoneNumber	Número de contacto con formato internacional
domain	Dominio web asociado
url	Enlace web externo del establecimiento
coor	Coordenadas espaciales (latitud, longitud)
stars	Calificación promedio histórica (1 a 5)
reviews	Volumen total de reseñas recibidas
source_query	Consulta origen utilizada para la extracción

Para asegurar una extracción exhaustiva, antes de la ejecución se generaron dinámicamente consultas cruzando cada distrito con categorías gastronómicas clave (e.g., chifa, pizzería). Durante la ejecución, se mantuvo un registro detallado de operaciones que garantizó la trazabilidad y la resiliencia del orquestador. Posteriormente, el pipeline de ETL de este módulo ejecutó la limpieza y deduplicación nacional utilizando el identificador *Place ID* de Google. Esto permitió consolidar miles de archivos en un único archivo CSV con 50 mil locales de restaurantes registrados en Google Maps que luego fue comprimido a Parquet. Tras una limpieza manual de registros que no eran restaurantes y de restaurantes con cero estrellas (sin reseñas), se generó el conjunto de datos final de restaurantes, depurado, con 39947 registros. En la Tabla I se describen las variables obtenidas.

III-A2. Extracción de reseñas: Con el listado maestro de restaurantes generado, se desarrolló un segundo orquestador de concurrencia asíncrona enfocado en la extracción del histórico de reseñas. Para superar las severas exigencias de memoria volátil (RAM) de Chromium al realizar desplazamientos verticales (desplazamientos) progresivos en la página, se implementó un modelo basado en corrutinas mediante `asyncio`. El orquestador emplea una única instancia de navegador en modalidad *headless*, subdividida en múltiples contextos aislados (contextos de navegador) que operan de forma simultánea consumiendo los *Place IDs* de una cola.

Para evadir bloqueos y acelerar el tiempo de carga, se implementó un mecanismo interceptor de red (modo sigiloso) que prohíbe proactivamente la descarga de imágenes, vectores cartográficos 3D y secuencias de telemetría publicitaria; ello también reduce el consumo de recursos. Paralelamente, se enmascaró la huella digital del proceso automatizado modificando banderas como `AutomationControlled`. La persistencia concurrente se aseguró mediante bloqueos lógicos (`asyncio.Lock`) para escribir el CSV consolidado y mediante el mantenimiento de una bitácora (`completed_places.txt`) que registra el estado en tiempo real para recuperaciones seguras.

Ante cualquier fallo del sistema, este orquestador lee automáticamente una lista de lugares ya completados (archivo

Tabla II
DESCRIPCIÓN DE VARIABLES DEL DATASET DE RESEÑAS

Variable	Descripción
place_id	Llave foránea del restaurante extraído
id_review	Identificador único de la reseña (*hash*)
caption	Contenido textual redactado en la reseña
relative_date	Fecha relativa de la publicación (e.g., "hace 2 meses")
review_date	Fecha y hora exacta de la publicación original
retrieval_date	Marca temporal del momento de extracción
rating	Calificación numérica otorgada (1 a 5)
username	Nombre o seudónimo del usuario crítico
n_review_user	Cantidad histórica de reseñas del usuario
n_photo_user	Cantidad histórica de fotografías del usuario
url_user	Enlace al perfil de Google del usuario
url_source	Enlace directo a la reseña original en Google Maps

TXT) para evitar reextraer *Place IDs* ya procesados, anexando los nuevos datos de forma continua al archivo de reseñas CSV en bruto. Dada la agresiva acumulación del DOM, se ejecutó previamente una prueba de rendimiento (véase el Apéndice A) que permitió ajustar empíricamente el límite máximo de trabajadores paralelos, balanceando el consumo de memoria y maximizando la velocidad de extracción de reseñas. Finalmente, un módulo ETL automatizado procesa las reseñas en crudo, deduplicando por review_id y exportando la información en formato `Parquet`. El *dataset de reseñas* final, cuyas variables se describen en la Tabla II, cuenta con 1 millón 800 mil registros.

III-B. Procesamiento de Datos

Para la manipulación y preparación de los datos en bruto, se utilizó la librería *pandas* sobre un entorno de Python. Debido al volumen de registros (aprox. 1.8 millones), el flujo de trabajo se optimizó mediante la conversión del archivo fuente CSV al formato *Apache Parquet*. Este formato de almacenamiento columnar permitió reducir los tiempos de entrada/salida y el consumo de memoria en los procesos subsecuentes, facilitando el uso de puntos de control (*checkpoints*) entre etapas.

III-B1. Limpieza de Datos: El proceso de limpieza se enfocó en asegurar la integridad y consistencia del corpus textual mediante las siguientes acciones:

- **Tratamiento de valores nulos:** Se identificaron registros con ausencia de texto en la variable *caption*. Estos valores fueron sustituidos por cadenas vacías para mantener la coherencia en las operaciones de vectorización, preservando el valor de la calificación (*rating*) asociada.
- **Eliminación de duplicados:** Se realizó un filtrado basado en el identificador único *id_review*, eliminando redundancias generadas durante la fase de extracción (*web scraping*).
- **Estandarización de texto:** Se implementó una rutina de normalización que incluyó la conversión a minúsculas, la eliminación de caracteres especiales, puntuación y elementos no alfanuméricos (emojis), asegurando un formato uniforme para el análisis de lenguaje natural.

III-B2. Transformación de Datos: Tras la limpieza, se aplicaron técnicas de ingeniería de características y preprocesamiento para NLP:

- **Gestión temporal:** Las marcas de tiempo originales fueron transformadas al tipo de dato *Timestamp* de pandas, permitiendo análisis de series temporales y estacionalidad.
- **Ingeniería de Características:** Se generaron nuevas variables métricas, incluyendo la longitud de caracteres (*text_len*) y el conteo de palabras (*word_count*). Asimismo, se realizó un *binning* de las calificaciones numéricas en categorías discretas (Baja, Media, Alta).
- **NLP Preparatorio:** Utilizando la suite *NLTK*, se procedió con la tokenización del texto y la eliminación de palabras de parada (*stopwords*) en español. Finalmente, se aplicó un proceso de lematización para reducir las palabras a su raíz morfológica, optimizando la dimensionalidad para futuros modelos de aprendizaje automático.

III-C. Almacenamiento de datos

Para garantizar la escalabilidad, gobierno y calidad de la información recopilada, se definió una arquitectura de datos basada en el paradigma de arquitectura medallón implementada sobre la plataforma Databricks. Esta estructura organiza los datos en tres capas lógicas de refinamiento progresivo.

III-C1. Capa de Bronce: Esta capa actúa como el repositorio de ingesta primaria (lago de datos). Aquí se volcaron los archivos crudos generados directamente por los orquestadores de extracción (`Perú.csv` y `reviews_raw.csv`) transitados a formato `Parquet`. El objetivo de la capa de Bronce es preservar la inmutabilidad histórica y el linaje de los datos originales, sirviendo como respaldo seguro ante cualquier fallo.

III-C2. Capa de Plata: En esta etapa, los datos provenientes de la capa de Bronce fueron sometidos a procesos estructurados de limpieza y estandarización. Se ejecutaron las rutinas de eliminación de caracteres no imprimibles y el tratamiento de valores nulos descritos en la fase de procesamiento. Asimismo, se unificaron las bases de restaurantes y reseñas mediante esquemas relacionales, produciendo una versión depurada e integrada de los datos.

III-C3. Capa de Oro: La capa de Oro representa el nivel máximo de refinamiento, diseñada específicamente para el consumo directo por parte de modelos analíticos. En esta fase, los datos de la capa de Plata fueron agregados, pivotados y sumarizados para generar métricas precalculadas. Se construyeron esquemas que consolidan estadísticas de calificación por distrito, recuentos de categorías y matrices dispersas necesarias para los algoritmos de aprendizaje automático.

III-D. Modelado descriptivo y visualización

A partir de la información consolidada, se desarrolló una fase de análisis exploratorio orientada a comprender el panorama del sector gastronómico peruano a partir de las reseñas obtenidas de Google Maps.

III-D1. Distribución geográfica de los datos: Para el análisis espacial de la oferta, se empleó la librería `GeoPandas` en Python, cruzando la información georeferenciada (archivos obtenidos de un repositorio público disponible en *GitHub*: https://github.com/juaneladio/peru-geojson) de los registros de los restaurantes con polígonos vectoriales correspondientes a las fronteras distritales y regionales del Perú. Se generaron mapas de calor (mapas de calor) y mapas coropléticos para visualizar la densidad de oferta gastronómica a lo largo del territorio nacional. Esto permitió identificar de manera visual clústeres de alta concentración comercial frente a zonas desatendidas, así como correlacionar espacialmente la polaridad de las calificaciones otorgadas en distintas regiones del país.

III-D2. Distribución temporal de los datos: Para analizar la estacionalidad y el comportamiento histórico de los consumidores, se emplearon representaciones gráficas de series temporales. Mediante gráficos de líneas y diagramas de barras continuas, se proyectó el volumen de publicaciones de reseñas a lo largo de los meses y años extraídos. El objetivo de estas visualizaciones fue revelar patrones de crecimiento de la adopción digital en la plataforma, identificar el impacto de variables exógenas (como periodos vacacionales o restricciones sanitarias) en el flujo de visitas a restaurantes, y detectar tendencias a largo plazo en el sentimiento o calificación promedio de los establecimientos.

III-E. Modelado analítico y entrenamiento

Concluida la fase descriptiva, se aplicaron técnicas avanzadas de aprendizaje automático no supervisado y sistemas predictivos para extraer patrones latentes de comportamiento y preferencia a partir del texto y de las interacciones numéricas.

III-E1. Agrupamiento de tipos de usuarios: Se buscó perfilar el comportamiento de los clientes mediante aplicando (*clustering*) a través de K-Means. Los usuarios fueron segmentados en grupos basados en vectores de características que resumen su actividad: frecuencia de reseñas, dispersión y media de calificaciones otorgadas, y proporción de reseñas con comentarios textuales. Este agrupamiento tuvo como objetivo descubrir arquetipos de clientes, diferenciando perfiles que van desde usuarios esporádicos o excesivamente benévolos, hasta «críticos severos» o perfiles potencialmente anómalos (*spammers*).

III-E2. Modelamiento de tópicos en reseñas: Para procesar el volumen masivo de texto no estructurado, se aplicaron algoritmos de Procesamiento de Lenguaje Natural (NLP) orientados al descubrimiento de temas latentes. Mediante *Latent Dirichlet Allocation* (LDA) se analizó el corpus general de reseñas para identificar qué dimensiones del servicio discuten con mayor frecuencia los consumidores peruanos (por ejemplo: sazón de la comida, rapidez del servicio, higiene, o infraestructura del local). Posteriormente, se asignó a cada restaurante una distribución probabilística de los tópicos más relevantes que predominan en su historial de críticas.

III-F. Evaluación y validación

El rendimiento empírico y la viabilidad de los modelos analíticos propuestos fueron sometidos a métricas de validación cuantitativas y particiones metodológicas rigurosas.

En los enfoques de aprendizaje no supervisado, la validación se realizó mediante métricas intrínsecas: para el agrupamiento de usuarios, se utilizó el coeficiente de silueta (*Silhouette Score*) a fin de medir la cohesión intra-clúster y la separación inter-clúster, asegurando una partición objetiva del público. En el modelamiento de tópicos, se optimizó empíricamente la cantidad de temas basándose en la métrica de coherencia semántica (*Coherence Score*), priorizando la interpretabilidad humana de los tópicos generados.

IV. Resultados y discusión

En esta sección se presentan los principales hallazgos derivados de la construcción del repositorio nacional de restaurantes y de la extracción masiva de reseñas desde Google Maps. En conjunto, la evidencia obtenida permite caracterizar la estructura espacial del mercado gastronómico digital peruano, su dinámica temporal y la heterogeneidad del comportamiento de los usuarios que participan en la plataforma.

IV-A. Panorama general del repositorio construido

La fase de recolección permitió consolidar un conjunto de datos final de 39947 restaurantes y aproximadamente 1.8 millones de reseñas, lo que confirma la factibilidad operativa del *pipeline* propuesto para capturar información a escala nacional. En términos empíricos, este volumen constituye una base robusta para estudiar simultáneamente dimensiones espaciales, temporales y textuales del ecosistema gastronómico peruano, y representa una cobertura difícil de alcanzar mediante levantamientos manuales o consultas acotadas. La magnitud del repositorio resulta especialmente relevante porque combina casi cuarenta mil unidades de análisis con una masa textual suficiente para comparar patrones entre regiones, segmentos de usuarios y categorías reputacionales dentro de una misma arquitectura de datos.

Más allá del volumen alcanzado, el principal resultado de esta etapa es la construcción de un repositorio integrado que vincula atributos del establecimiento, coordenadas geográficas, intensidad de participación de los usuarios, calificaciones históricas y contenido textual de las reseñas. Esta integración permite pasar de una lógica meramente descriptiva, centrada en conteos aislados, a un enfoque analítico capaz de relacionar territorio, reputación digital y comportamiento del consumidor en una misma estructura de datos.

La Tabla III resume los principales hallazgos agregados del análisis, mientras que las Figuras 1, 4, 6 y 7 sintetizan visualmente los patrones espaciales, temporales y analíticos más relevantes. Los resultados de mayor detalle visual se presentan en el Apéndice B.

IV-B. Estructura territorial de los restaurantes y sus reseñas en Google Maps

Los resultados espaciales evidencian una estructura marcadamente concentrada de la oferta gastronómica

Tabla III
RESUMEN DE HALLAZGOS PRINCIPALES

Dimensión	Hallazgo principal
Cobertura de datos	Se consolidaron 39947 restaurantes y aproximadamente 1.8 millones de reseñas con cobertura nacional.
Patrón espacial	La oferta gastronómica digital se concentra en Lima Metropolitana y en capitales regionales, con menor densidad relativa en zonas periféricas.
Patrón temporal	El volumen de reseñas presenta ciclos recurrentes y una dinámica no estacionaria, consistente con procesos de adopción digital y estacionalidad del consumo.
Segmentación de usuarios	El agrupamiento identifica perfiles de usuarios diferenciados por intensidad de participación y severidad al calificar.
Estructura temática	El modelamiento de tópicos revela dimensiones recurrentes asociadas con comida, servicio, experiencia del local y evaluación global.

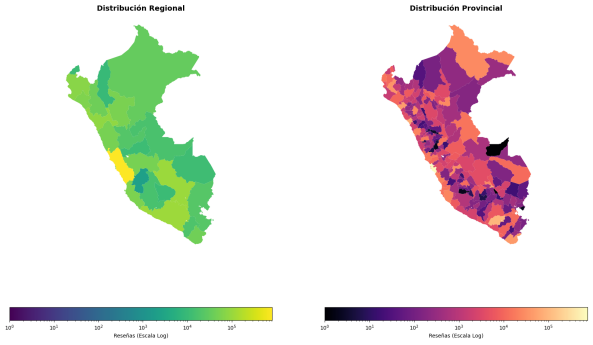

Figura 1. Distribución geográfica de reseñas por región y provincia.

comercial. Las Figuras 1 y 2 muestran que la densidad de establecimientos registrados y con actividad de reseñas no se distribuye homogéneamente en el territorio, sino que se agrupa en los principales núcleos urbanos. Lima destaca como el principal polo de concentración, lo que resulta esperable por su peso demográfico, centralidad económica y mayor penetración de plataformas digitales. No obstante, la presencia de conglomerados relevantes fuera de la capital sugiere que la huella digital del consumo gastronómico ya no es exclusivamente metropolitana, sino que se extiende a ciudades intermedias y capitales regionales.

Este patrón es relevante porque indica que la visibilidad en plataformas no depende únicamente de la existencia física de establecimientos, sino también de la intensidad con la que los consumidores interactúan digitalmente con ellos. En otras palabras, el mapa de restaurantes en Google Maps no debe leerse solo como una cartografía de oferta, sino como una cartografía de oferta más trazabilidad digital. Ello implica que las regiones con menor densidad observada pueden reflejar simultáneamente una menor concentración comercial, menores niveles de digitalización o una menor propensión de los usuarios a dejar reseñas.

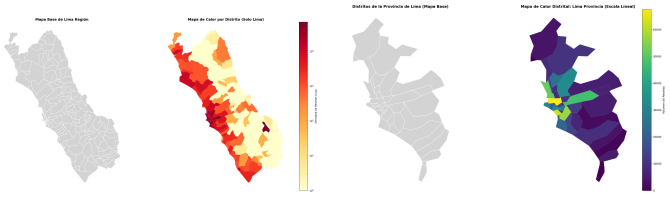

(a) Distribución geográfica a nivel provincial de Lima región.

(b) Distribución geográfica a nivel distrital de Lima provincia.

Figura 2. Desagregación espacial de la actividad de reseñas gastronómicas en Lima.

IV-C. Dinámica temporal de la participación y las calificaciones

Desde una perspectiva temporal, las Figuras 4 y 5 revelan que la actividad de reseñas responde a patrones recurrentes más que a una generación aleatoria de contenido. En particular, la distribución temporal agregada sugiere una expansión progresiva del volumen de interacciones en el tiempo, compatible con una mayor adopción de Google Maps como infraestructura de reputación digital. A nivel de periodicidad corta, la serie semanal indica oscilaciones sistemáticas en la frecuencia de publicación, lo que sugiere una relación estrecha entre comportamiento de consumo, temporalidad de visitas y propensión a dejar retroalimentación.

La matriz temporal de puntajes añade un matiz importante a esta lectura. Aunque el volumen de participación varía a lo largo del tiempo, la estructura de las calificaciones parece mantener una estabilidad relativa, lo que sugiere que el crecimiento de la base de reseñas no altera de manera drástica la lógica de valoración agregada. Este hallazgo es metodológicamente importante, porque indica que el incremento del volumen de datos no necesariamente

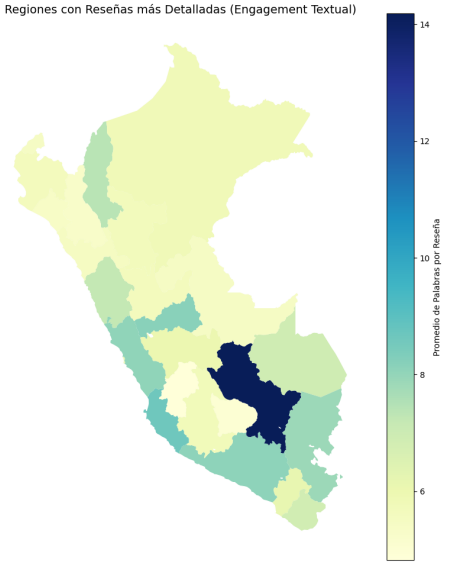

Figura 3. Detalle espacial de palabras por reseña.

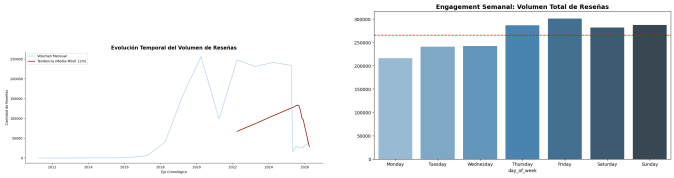

(a) Distribución temporal agregada de reseñas.

(b) Distribución temporal semanal de reseñas.

Figura 4. Evolución temporal de la participación en la plataforma.

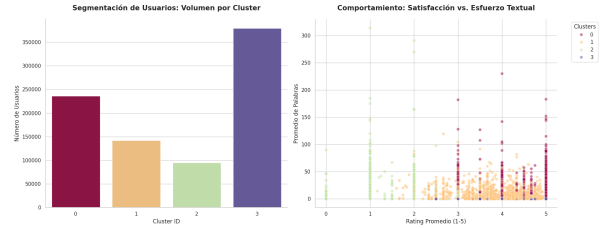

Figura 6. Visualización de clústeres de usuarios obtenidos mediante K-Means.

introduce una deriva sistemática en la señal reputacional observada, sino que más bien fortalece su granularidad y capacidad de seguimiento.

En línea con ello, la Tabla IV muestra que las reseñas negativas son menos frecuentes, pero considerablemente más extensas que las positivas y medias. Mientras que la categoría alta concentra la mayor masa de observaciones, las reseñas bajas presentan en promedio mayor número de caracteres y palabras. Este resultado sugiere que la insatisfacción induce comentarios más elaborados, lo que convierte a las reseñas negativas en una fuente especialmente rica para tareas de minería de opinión y diagnóstico operativo.

IV-D. Segmentación de usuarios y estructura temática de las reseñas

En el plano analítico, la Figura 6 muestra que la segmentación de usuarios mediante K-Means produce una estructura interpretable y con separación apreciable entre grupos. Los diagnósticos complementarios de selección y validación del agrupamiento se presentan en el Apéndice B. Aunque la selección final del número de clústeres debe sustentarse en el equilibrio entre parsimonia e interpretabilidad, la evidencia visual del método del codo y del análisis de silueta sugiere que un número reducido de segmentos captura adecuadamente la heterogeneidad del comportamiento revisor. La proyección de clústeres permite distinguir, al menos cualitativamente, perfiles de baja intensidad, usuarios recurrentes con comportamiento relativamente estable y perfiles más extremos en frecuencia o severidad de evaluación.

El resumen cuantitativo de los clústeres refuerza esta interpretación. Los clústeres 0 y 3 agrupan usuarios con baja frecuencia de reseña (1.34 y 1.29, respectivamente), altas calificaciones promedio (4.80 y 4.56) y muy baja dispersión, lo que es compatible con perfiles benévolos y de baja participación. El clúster 2 concentra usuarios poco frecuentes pero marcadamente críticos, con calificación media cercana a 1.43 y variabilidad mínima. En contraste, el clúster 1 exhibe el mayor volumen de actividad (5.97 reseñas promedio), una calificación más moderada (3.81) y la mayor desviación estándar (1.22), lo que sugiere un segmento de usuarios intensivos y más heterogéneos en su patrón valorativo.

Por su parte, la Figura 7 y la Tabla V indican que el corpus textual de reseñas contiene una estructura temática identificable. Los términos dominantes se organizan principalmente alrededor de ejes asociados con comida, atención, ambiente, precio y experiencia general, lo cual es coherente con la literatura sobre minería de opiniones en reseñas de restaurantes. La perplejidad del modelo (2383.15) se reporta como métrica interna de ajuste; sin embargo, su interpretación aislada es limitada en modelos de tópicos, por lo que se complementa con criterios de coherencia semántica para priorizar la interpretabilidad de los tópicos obtenidos.

IV-E. Discusión integrada e implicancias

Los hallazgos observados son consistentes con la literatura que describe una fuerte concentración espacial de la actividad económica digital en grandes centros urbanos y una sobrerrepresentación de usuarios intensivos en plataformas de reseñas. En ese sentido, el patrón encontrado para Lima y otras capitales regionales coincide con estudios previos que muestran que la visibilidad digital de establecimientos depende, en parte, de la densidad urbana, del acceso a

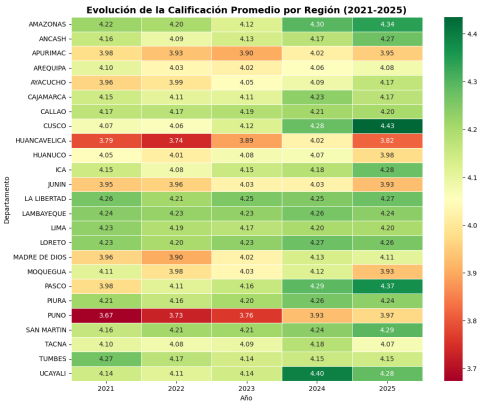

Figura 5. Matriz temporal de puntajes y comportamiento de calificaciones.

Tabla IV
ENGAGEMENT TEXTUAL POR CATEGORÍA DE CALIFICACIÓN

Categoría	Reseñas	Prom. car.	Prom. pal.	Part. (%)
Alta	1446040	39.24	6.62	78.13
Media	203000	40.72	7.23	10.97
Baja	200328	91.55	16.48	10.82
Sin texto / nula	6031	60.80	10.20	0.33

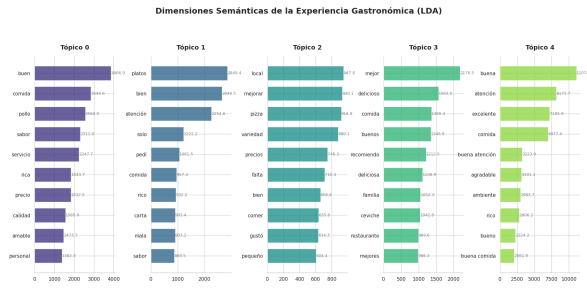

Figura 7. Visualización de tópicos obtenidos mediante LDA.

conectividad y de la mayor probabilidad de interacción en plataformas. Del mismo modo, la identificación de perfiles diferenciados de revisores converge con la literatura sobre reputación en línea, que suele distinguir entre usuarios ocasionales, contribuyentes frecuentes y segmentos con mayor polarización valorativa.

Sin embargo, el presente trabajo aporta una escala y una integración metodológica menos frecuentes en estudios previos aplicados al contexto peruano. A diferencia de aproximaciones focalizadas en una sola ciudad, en una categoría específica o en muestras reducidas de establecimientos, la estrategia propuesta integra cobertura territorial amplia, histórico de reseñas, atributos espaciales y modelamiento textual en un único flujo analítico. Esta combinación no solo incrementa la capacidad descriptiva del estudio, sino que mejora su potencial de reutilización para tareas posteriores de predicción, recomendación y vigilancia del mercado.

Los resultados sugieren que Google Maps puede emplearse como una fuente de datos válida para aproximar la estructura territorial y reputacional del sector gastronómico peruano, siempre que se reconozcan sus sesgos inherentes. Entre ellos destacan la mayor visibilidad de zonas urbanas, la dependencia de la participación digital de los usuarios y la posible subrepresentación de establecimientos informales o de baja presencia en línea. Aun con estas restricciones, la consistencia entre patrones espaciales, temporales y temáticos indica que el repositorio capturado retiene suficiente señal para análisis estratégicos de alto valor.

Tabla V
TÓPICOS DETECTADOS EN LAS RESEÑAS Y TÉRMINOS DOMINANTES

Tópico	Términos dominantes
0	buen, comida, pollo, sabor, servicio, rica, precio, calidad, amable, personal
1	platos, bien, atención, solo, pedí, comida, rico, carta, mala, sabor
2	local, mejorar, pizza, variedad, precios, falta, bien, comer, gustó, pequeño
3	mejor, delicioso, comida, buenos, recomiendo, deliciosa, familia, ceviche, restaurante, mejores
4	buena, atención, excelente, comida, buena atención, agradable, ambiente, rico, bueno, buena comida

Desde una perspectiva aplicada, la evidencia obtenida habilita al menos tres usos relevantes. Primero, permite mapear desigualdades territoriales en la oferta gastronómica digital y detectar zonas con mayor saturación competitiva o menor visibilidad en plataformas. Segundo, posibilita perfilar segmentos de usuarios y entender cómo distintos tipos de revisores influyen en la reputación agregada de los establecimientos. Tercero, abre la puerta a sistemas de recomendación y monitoreo continuo que combinen ubicación, historial de calificaciones y contenido textual para apoyar decisiones empresariales y de política pública.

En conjunto, los resultados validan la utilidad del enfoque de analítica de macrodatos adoptado y muestran que la combinación de raspado web, procesamiento distribuido y análisis exploratorio avanzado constituye una vía robusta para estudiar fenómenos de consumo digital a escala nacional. Como borrador de investigación, esta sección deja planteada una base empírica consistente sobre la cual pueden incorporarse, en versiones posteriores, métricas inferenciales más finas, validaciones externas y comparaciones formales entre algoritmos.

V. CONCLUSIÓN

Este estudio demostró la viabilidad de un *framework* de big data para capturar, integrar y analizar información gastronómica a escala nacional a partir de datos públicos de Google Maps. La construcción de un repositorio con 39947 restaurantes y aproximadamente 1.8 millones de reseñas permitió identificar patrones territoriales, temporales y temáticos del mercado gastronómico digital peruano, así como distinguir perfiles de usuarios con comportamientos valorativos diferenciados. En conjunto, los resultados muestran que las reseñas en plataformas digitales no solo reflejan reputación, sino también dinámicas de concentración, participación e interacción que resultan útiles para comprender mejor la estructura competitiva del sector.

El principal aporte del trabajo consiste en convertir una fuente dispersa de contenido generado por usuarios en una base analítica con valor práctico para la industria gastronómica peruana. Desde esta perspectiva, el *framework* propuesto puede servir como herramienta de inteligencia competitiva para identificar zonas de alta competencia, monitorear percepciones de servicio, reconocer patrones de insatisfacción y apoyar decisiones empresariales, gremiales o públicas con evidencia más amplia y actualizable. Así, la contribución del estudio no radica solo en el diseño técnico de la arquitectura, sino en su capacidad para traducir datos masivos en conocimiento accionable para un sector altamente fragmentado y competitivo.

No obstante, los hallazgos deben interpretarse considerando que la evidencia depende de la cobertura, sesgos y niveles de participación propios de Google Maps, por lo que no

representa exhaustivamente a todo el universo de restaurantes ni permite establecer relaciones causales fuertes. Como trabajo futuro, resulta pertinente integrar otras fuentes digitales y operativas, fortalecer la validación empírica de los modelos y avanzar hacia sistemas de monitoreo continuo y analítica predictiva. Bajo ese enfoque, el mayor valor del estudio está en mostrar que la analítica masiva puede pasar de ser un ejercicio descriptivo a convertirse en una infraestructura estratégica para mejorar la comprensión, la gestión y la competitividad de la industria gastronómica peruana.

Apéndice A
Benchmark de concurrencia y ajuste de workers

Se realizó un benchmark para identificar una configuración de concurrencia que maximizara la velocidad de extracción sin comprometer la integridad de los datos. La prueba comparó 4, 8 y 12 *workers* simultáneos sobre una muestra fija de 50 restaurantes, con un máximo de 50 reseñas por local.

La configuración de 8 *workers* ofreció el mejor equilibrio entre rendimiento e integridad: redujo el tiempo total a 155.4 s y alcanzó 1251 reseñas extraídas sin errores críticos. Aunque 12 *workers* redujo marginalmente el tiempo total, produjo una caída severa en el volumen recuperado, por lo que se descartó como configuración operativa.

Workers	Tiempo total (s)	Tiempo/local (s)	Reseñas extraídas	Errores críticos
4	237.9	4.8	1227	0
8	**155.4**	**3.1**	**1251**	**0**
12	142.5	2.9	724	0

Tabla VI. Benchmark de concurrencia (50 locales; máximo 50 reseñas por local).

Apéndice B
Resultados suplementarios

Este apéndice reúne únicamente los diagnósticos complementarios del modelo K-Means utilizados para justificar la selección del número de clústeres y evaluar la calidad del agrupamiento principal.

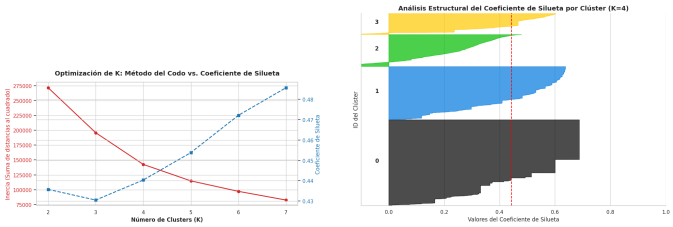

(a) Método del codo para la selección de clústeres.

(b) Análisis de silueta del agrupamiento.

Figura 8. Diagnósticos complementarios de validación para el modelo K-Means.

Referencias

[1] Redacción El Comercio, «Mincetur: Menos del 1 % de restaurantes formales del país podrá funcionar en reinicio de actividades,» *El Comercio*, abril de 2020, Declaraciones del ministro Edgar Vásquez, MINCETUR. dirección: https://elcomercio.pe/economia/peru/coronavirus-peru-mincetur-menos-del-1-de-restaurantes-formales-del-pais-podra-funcionar-en-reinicio-de-actividades-apps-de-delivery-covid-19-nndc-noticia/

[2] B. Liu, *Sentiment Analysis and Opinion Mining* (Synthesis Lectures on Human Language Technologies). Morgan & Claypool Publishers, 2012. DOI: 10.2200/S00416ED1V01Y201204HLT016

[3] D. M. Blei, A. Y. Ng y M. I. Jordan, «Latent Dirichlet Allocation,» *Journal of Machine Learning Research*, vol. 3, págs. 993-1022, 2003.

[4] M. Grootendorst, «BERTopic: Neural topic modeling with a class-based TF-IDF procedure,» *arXiv preprint arXiv:2203.05794*, 2022. dirección: https://arxiv.org/abs/2203.05794

[5] J. García-Gómez, «Analyzing the growth of the digital footprint in gastronomic SMEs and its correlation with business survival,» *Technological Forecasting and Social Change*, vol. 188, pág. 122 285, 2023.

[6] P. Silva, R. Costa y N. Pereira, «Evaluating the adoption of Big Data architectures in the hospitality sector: A systematic review,» *IEEE Transactions on Big Data*, vol. 8, n.º 4, págs. 950-964, 2022.

[7] L. Zhao, S. Wu e Y. Sun, «Building a food industry market observatory using big data architectures,» *Data Science and Management*, vol. 7, n.º 1, págs. 45-56, 2024.

[8] S. Kim y J. Lee, «Evaluating how spatial distribution affects profitability in the gastronomic sector: An integrated regression model,» *Tourism Management*, vol. 89, pág. 104 462, 2022.

[9] R. Patel y A. Sharma, «Measuring the impact of Google Maps rating variations on restaurant revenues: A time series analysis,» *International Journal of Hospitality Management*, vol. 112, pág. 103 498, 2023.

[10] A. Martínez, L. García y M. Rodríguez, «Customer segmentation based on user-generated content: Unsupervised clustering approaches,» *Journal of Business Research*, vol. 170, pág. 114 321, 2024.

[11] Y. Zhang, H. Li y Z. Wang, «Analyzing online reviews to discover competitive advantages in restaurants: A natural language processing approach,» *Decision Support Systems*, vol. 165, pág. 113 876, 2023.

[12] D. Torres y E. Díaz, «Linking online complaints with restaurant operational inefficiencies using text mining,» *Computers in Industry*, vol. 145, pág. 103 810, 2023.

[13] X. Wang, Y. Chen y Q. Liu, «Identifying emerging food trends from online review platforms using topic mode-

ling and entity extraction,» *Information Processing & Management*, vol. 59, n.º 3, pág. 102 875, 2022.

[14] H. Liu y T. Chen, «Designing hybrid recommendation systems to increase customer lifetime value in restaurants,» *Expert Systems with Applications*, vol. 238, pág. 121 743, 2024.